

Diagnóstico de Datos y Hallazgos de Negocio

6 reglas de calidad · 3 hallazgos · Medidas de tendencia central · Patrones de consumo

Período	Clientes	Registros crudos	Silver limpio
Mayo–Junio 2026	CLI-001 · 002 · 003	4,359	4,300 (98.6%)
Corregidos			
266 (incl. 193 recuperados)			

CONTEXTO

Objetivo

Construir un proceso por capas que permita conocer el comportamiento de consumo energético en el tiempo, y sobre él un agente de IA que entregue resultados e insights bajo demanda — con cifras trazables hasta el registro de campo original. **Base:** datos ruidosos de campo + LLM que nunca inventa números.



El problema

Medidores con unidades mezcladas, formatos de fecha distintos y consumos nulos. Un agente sobre esos datos crudo daría cifras incorrectas.



La solución

Pipeline Bronze→Silver con 6 reglas que corrigen, recuperan y cuarentenan. El LLM solo recibe resultados pre-calculados — nunca opera sobre los datos.



El resultado

4,300 registros limpios. 193 de CLI-003 recuperados por detección de cambio de formato. Silver listo para análisis y agente LUMI.

Los 3 clientes

CLI-001

Textiles del Valle S.A.S

Ciudad	Yumbo
Industria	Textil · Tejeduría
Horario	L-S 06:00–22:00h
Tarifa	No regulado · Niv. 2
Solar	No
Jun	318,857 kWh

HALLAZGO

6% consumo fuera de horario

CLI-002

Frigorífico Andino S.A

Ciudad	Medellín
Industria	Alimentos · Refrigeración
Horario	24/7
Tarifa	No regulado · Niv. 3
Solar	380 kWp desde 2024
Jun	569,999 kWh

HALLAZGO

+31.6% jun vs may — solar sin medición

CLI-003

Clínica Santa Elena

Ciudad	Barranquilla
Industria	Salud · Hospitalario
Horario	24/7 + quirófanos L-V
Tarifa	Regulado
Solar	En evaluación
Jun	376,476 kWh (completo)

HALLAZGO

Formato fecha recuperado · 193 registros

PARTE A — ESTADÍSTICA

Medidas de tendencia central

Consumo horario en kWh · Silver limpio · Mayo–Junio 2026

Cliente	N	Media (kWh)	Mediana (kWh)	Moda (kWh)	Q1	Q3	IQR	Std	CV%	Min	Max
CLI-001 Textiles	1,399	430.6	492.1	509.9	68.2	532.1	463.9	1,997	464%	30.0	48,345
CLI-002 Frigorífico	1,450	691.8	584.8	578.7	472.3	615.0	142.7	2,266	328%	263.9	50,290
CLI-003 Clínica	1,451	505.6	355.2	339.5	337.7	461.8	124.1	1,825	361%	320.0	42,329

CLI-001 — Alta variabilidad


IQR de 463.9 y CV de 464% — los turnos de producción generan picos muy marcados vs las horas de inactividad ($Q1=68$ kWh).
Media (430) < Mediana (492): distribución sesgada a la izquierda por horas de madrugada con bajo consumo.

CLI-002 — Distribución compacta

IQR de 142.7 — el más concentrado, consistente con refrigeración 24/7 sin paradas.
Media (691) > Mediana (585): los outliers extremos jalan la media hacia arriba. Operación más predecible de los tres.

CLI-003 — Bimodal

Media (505) muy por encima de mediana (355) y moda (339): la distribución tiene una cola derecha pesada por los picos de quirófano. La moda y mediana son similares — consumo base hospitalario estable.



PARTE A — CALIDAD

6 reglas de calidad aplicadas

De 4,359 crudos → 266 corregidos · 47 cuarentenados · 12 descartados · **4,300 silver limpio (98.6%)**

Acción	N	Causa	Resultado
Corregidos	266	193 timestamps DD/MM/YYYY recuperados + 73 Wh→kWh	Datos correctos en silver
Cuarentenados	47	21 consumos nulos · 10 negativos · 16 duplicados ambiguos	Preservados con diagnóstico
Descartados	12	Duplicados exactos (reenvíos)	Sin pérdida de información
Flaggeados	18	consumo_kwh > $Q3 + 3 \times IQR$ por cliente	En silver con _outlier=True
Silver limpio	4,300	98.6% de los registros crudos	Listos para análisis y LUMI




Fig. 3 – Destino de registros · Problemas por tipo · Compleitud por cliente

REGLA 01 · CORRECCIÓN

● Timestamps DD/MM/YYYY — 193 registros CLI-003 recuperados

MTR-003 cambió de formato el 1 de junio (YYYY-MM-DD → DD/MM/YYYY). Los datos siempre estuvieron ahí — el pipeline los recupera con un segundo intento de parseo (dayfirst=True). Recuperación: 193/193 (100%).

Formato hallado: 01/06/2026 00:00
 Formato esperado: 2026-06-01 00:00:00
 Causa: Cambio de config. software medidor MTR-003

Detección: `pd.to_datetime → NaT` Acción: `retry dayfirst=True → silver`

REGLA 01b · CUARENTENA

● Consumos nulos — 21 registros

Timestamp válido pero consumo = NaN. Falla de lectura del sensor. 7 registros por cada cliente.

Detección: `consumo IS NULL`

Acción: `cuarentena 'consumo_nulo'`

REGLA 02 · CORRECCIÓN

● Unidades Wh / kWh mezcladas — CLI-002

73 registros en Wh (10–12 mayo). Sin corrección aparecerían 1,000× inflados. Conversión ÷1,000 verificada: mediana convertida = 580.3 vs kWh directa = 584.8 (diferencia <1%).

Detección: `unidad = 'Wh'` Acción: `÷1000 → kWh`

REGLA 03 · CUARENTENA

● Consumos negativos — 10 registros

Valores entre -70 y -233 kWh. Posible generación solar no etiquetada (CLI-002) o error de signo. Sin medidor bidireccional no es distinguible automáticamente.

Detección: `consumo_kwh < 0`

Acción: `cuarentena con flag`

REGLA 04 · DESCARTE

● Duplicados exactos — 12 reenvíos

12 filas idénticas en cliente + timestamp + consumo. Reenvíos del mensaje de telemetría. Se conserva el primero.

Detección: `duplicated(keep=first)` Acción: `descartar`

REGLA 05 · CUARENTENA

● Duplicados ambiguos — 16 slots

Mismo cliente + timestamp con consumos diferentes.
Imposible decidir sin revisar el medidor físico. Se cuarentenan ambas filas.

Detección: `GROUP BY HAVING COUNT(DISTINCT consumo) >1`

Acción: `cuarentena ambas`

REGLA 06 · FLAG EN SILVER – MÉTODO IQR (3×)

● Outliers extremos: $Q3 + 3 \times IQR$ · 18 horas (CLI-001=5, CLI-002=7, CLI-003=6)

Se usa el método IQR con fence de $3 \times$ (vs el estándar $1.5 \times$) para capturar solo outliers verdaderamente extremos, reduciendo falsos positivos en clientes industriales con alta varianza natural. Los 18 registros quedan en silver con `_outlier=True`.

	Q1	Q3	IQR	Fence $3 \times IQR$	Outliers
CLI-001:	68.2	532.1	463.9	1,923.7 kWh	4 (max 48,345)
CLI-002:	472.3	615.0	142.7	1,043.1 kWh	7 (max 50,290)
CLI-003:	337.7	461.8	124.1	834.1 kWh	5 (max 42,329)

Detección: `consumo_kwh > Q3 +  $3 \times IQR$  por cliente`

Acción: `_outlier=True – permanece en silver`



Fig. 4 – Outliers detectados por cliente (▲ rojo = $> Q3+3 \times IQR$) · CLI-001: 5 · CLI-002: 7 · CLI-003: 6 · Total: 18

PARTE A – HALLAZGOS DE NEGOCIO

Los 3 hallazgos más valiosos

HALLAZGO 01 – AHORRO CLI-001 • 6% del consumo fuera del horario declarado

Textiles opera L-S 06:00–22:00h, pero hay consumo sostenido en madrugada y domingos — no es ruido, es 76.8 kWh/h promedio constante vs 608.5 kWh/h dentro del turno.

35,943

kWh fuera de horario

6.0%

del total

76.8

kWh/h promedio fuera

Martes

pico nocturno

CLI-001 Textiles del Valle — Análisis de horario




Fig. 5 – Dentro/fuera horario · Promedio por hora · Nocturno por día

Hipótesis: Chiller 120 kW + compresores 75 kW no se apagan al fin del turno.

→ Submedición en chiller y compresores para aislar la carga. Si es consumo fantasma: **~35,000 kWh/ bimestre recuperables** con automatización de apagado.

HALLAZGO 02 – FACTURACIÓN

CLI-002 · +31.6% en junio con 380 kWp solares instalados

Junio sube 136,937 kWh vs mayo. El sistema solar existe desde 2024 pero la telemetria no mide generación — **el ROI del solar es incalculable** con los datos actuales.

433,062

kWh mayo

569,999

kWh junio

+31.6%

variación

33.4%

consumo diurno

10

negativos en cuarentena

CLI-002 Frigorífico Andino — Sistema solar 380 kWp (2024)




Fig. 6 – Mayo vs junio por hora · Diurno vs nocturno · Tendencia semanal

Hipótesis: Mayor demanda operativa en junio. Los 10 negativos en cuarentena pueden ser generación solar inyectada — sin medidor bidireccional no se puede confirmar.

→ Instalar **medidor bidireccional en el inversor** para separar consumo de red vs autoconsumo. Sin ese dato no se puede demostrar el ahorro del solar ni detectar degradación.

HALLAZGO 03 – CALIDAD + SOLAR

CLI-003 · Cambio de formato en medidor — datos recuperados + candidato solar

Corrección al diagnóstico inicial: El "gap de 8 días" no existía — era un cambio de formato de fecha en MTR-003. Los 193 registros fueron recuperados. Variación real junio vs mayo: **+5.4%** (no -27%).

193

registros recuperados

376,476

kWh junio real

+5.4%

variación real

33%

consumo diario → solar




Fig. 7 – Serie recuperada · Perfil hospitalario · Mayo vs junio real

Causa: Cambio de configuración software MTR-003 el 01/06. Solución definitiva: estandarizar a ISO 8601.

PARTE A — PATRONES

Patrones: hora × día de semana




Fig. 8 — Heatmap kWh/h promedio por hora y día · CLI-001: picos en turno, cola nocturna · CLI-002: uniforme 24/7 · CLI-003: picos quirófano días hábiles




Fig. 9 — Potencial solar: % consumo en franja 08:00-17:00h · CLI-001 mayor candidato (52.6%) sin sistema · CLI-002 instalado pero sin medición · CLI-003 moderado en evaluación

